Segmentación de canciones de Spotify mediante Clustering

Saidy Julieth Bonilla Cachaya, Fernando Novoa Salazar, Leticia Martínez Sánchez, Eduar Mauricio Méndez Méndez
Universidad Nacional de Colombia
Minería de Datos 2026-1
Bogotá, Colombia
{sabonillac, fnovoas, lmartinezsa, edmendezm}@unal.edu.co

***Resumen*—Este artículo presenta el desarrollo de un sistema de análisis de canciones de Spotify orientado a estados de ánimo y género musical mediante técnicas de minería de datos [1]. A partir de un conjunto inicial de 114,000 registros, se aplicó la metodología KDD incorporando preprocesamiento avanzado con transformaciones logarítmicas para corregir asimetrías y codificación cíclica (*Circular Encoding*) para variables tonales y rítmicas [1] [2]. El estudio integró el descubrimiento de patrones de co-ocurrencia mediante reglas de asociación (Apriori y FP-Growth), identificando un núcleo acústico-energético con niveles de *lift* de hasta 2.72. Asimismo, se realizó una segmentación no supervisada evaluando algoritmos de *clustering* (K-Means, GMM, jerárquico y HDBSCAN), determinando una estructura óptima de 5 segmentos musicales. Complementariamente, se implementó un módulo de clasificación supervisada para predecir el género musical (`track_genre`) a partir de 14 descriptores acústicos, comparando Random Forest, Histogram Gradient Boosting y regresión logística multinomial; el Random Forest alcanzó un 30.3 % de *accuracy* y un F1 macro de 0.286 sobre ∼114 clases. Los resultados, validados mediante el modelo circunflejo de Russell y proyecciones no lineales UMAP, demuestran que las dimensiones acústicas permiten capturar estados emocionales funcionales y patrones de género parcialmente recuperables que trascienden las etiquetas convencionales.**

***Index Terms*—minería de datos, Spotify, preprocesamiento, análisis exploratorio de datos, clustering, clasificación, PCA, asociación, agrupación, Random Forest, K-means, GMM, jerárquico, HDBSCAN**

I. Introducción

El crecimiento de plataformas de streaming ha incrementado la disponibilidad de datos acústicos de alta granularidad, permitiendo estudiar patrones musicales más allá de etiquetas tradicionales de género. En este contexto, se desarrolló un proyecto de minería de datos para analizar pistas de Spotify con el fin de identificar segmentos musicales orientados a estados de ánimo, descubrir patrones de co-ocurrencia entre sus atributos acústicos y evaluar la capacidad predictiva de dichos descriptores para clasificar el género musical.

El objetivo central fue implementar una metodología integral basada en el proceso KDD, que abarcó desde un preprocesamiento avanzado —incluyendo transformaciones logarítmicas y codificación cíclica— hasta el modelado no supervisado y supervisado. El trabajo integró el descubrimiento de reglas de asociación mediante los algoritmos Apriori y FP-Growth, junto con una segmentación de canciones que evaluó la consistencia de técnicas de agrupamiento como K-Means, GMM, clustering jerárquico y HDBSCAN. Como extensión del análisis, se desarrolló un módulo de clasificación supervisada para predecir el género musical (`track_genre`) a partir de descriptores acústicos, comparando Random Forest, Histogram Gradient Boosting y regresión logística multinomial. La interpretación de los hallazgos se fundamentó en el modelo circunflejo de Russell y se validó mediante proyecciones no lineales UMAP, permitiendo capturar una estructura emocional subyacente que trasciende las etiquetas de género convencionales.

II. Descripción del conjunto de datos

II-A. Fuente y alcance

Se utilizó el *Spotify Tracks Dataset* publicado en Kaggle [1]. El archivo principal `dataset.csv` tiene un tamaño aproximado de 20.12 MB y contiene 114,000 filas con 21 columnas.

La versión original reporta 125 géneros y una estructura balanceada por clase (2,280 canciones por género). Sin embargo, el análisis mostró que `track_id` no es estrictamente único por fila, por lo que existen repeticiones de una misma pista asociada a distintos contextos (álbum, edición o etiqueta de género).

II-B. Estructura de variables

El conjunto integra tres bloques principales:

Cuadro I
Estructura resumida del dataset

Bloque	Variables representativas
Identificadores y metadatos	`track_id`, `artists`, `album_name`, `track_name`, `track_genre`, `explicit`
Popularidad y duración	`popularity` (0–100), `duration_ms`
Características acústicas	`danceability`, `energy`, `loudness`, `speechiness`, `acousticness`, `instrumentalness`, `liveness`, `valence`, `tempo`, `key`, `mode`, `time_signature`

Dos retos fueron críticos desde el inicio: i) coexistencia de escalas incompatibles (por ejemplo, `loudness` en dB y `tempo` en BPM frente a variables en [0,1]); ii) presencia de valores atípicos en duración y speechiness.

III. Metodología KDD aplicada

La estrategia metodológica se implementó en seis fases integradas:

1. **Comprensión de datos:** revisión de tipado, semántica y calidad de las 21 variables originales del conjunto de datos [1].
2. **Limpieza y preprocesamiento:** deduplicación por *track_id*, tratamiento de nulos y aplicación de transformaciones logarítmicas para corregir asimetrías, junto con codificación cíclica (*Circular Encoding*) para preservar la proximidad musical en tonalidades y compases.
3. **Análisis Exploratorio (EDA):** análisis univariado y bivariado con énfasis en las correlaciones acústicas críticas (energía, volumen y acusticidad).
4. **Reducción de dimensionalidad:** implementación de PCA para eliminar la redundancia detectada en el EDA, seleccionando 9 componentes para retener el 80 % de la varianza acumulada.
5. **Minería de reglas de asociación:** descubrimiento de patrones de co-ocurrencia mediante los algoritmos Apriori y FP-Growth sobre atributos acústicos discretizados en niveles de intensidad.
6. **Segmentación y validación:** aplicación de modelos de *clustering* (K-Means, GMM, clustering jerárquico y HDBSCAN) y validación de los segmentos obtenidos mediante el modelo circunflejo de Russell y proyecciones no lineales UMAP.
7. **Clasificación supervisada:** predicción del género musical (`track_genre`) mediante Random Forest con ajuste de hiperparámetros, comparado frente a Histogram Gradient Boosting y regresión logística multinomial sobre las mismas particiones de entrenamiento y prueba.

IV. Análisis Exploratorio de Datos (EDA)

IV-A. Estadística descriptiva y distribuciones

Sobre la matriz preprocesada para modelado (86,467 registros), se observaron patrones consistentes:

- `instrumentalness` y `acousticness` con fuerte asimetría y alta concentración cercana a 0.
- `speechiness` predominantemente baja, coherente con pistas musicales no habladas.
- `valence` y `danceability` con distribuciones más equilibradas, útiles para perfilado emocional.
- `duration_ms` con mayor dispersión relativa, incluso tras filtros de limpieza.

IV-B. Matriz de correlación: resultados

El análisis de correlación reveló relaciones acústicas relevantes:

- `energy–loudness`: correlación positiva fuerte ($r \approx 0.75$).
- `energy–acousticness`: correlación negativa fuerte ($r \approx -0.74$).
- `loudness–acousticness`: correlación negativa moderada-fuerte ($r \approx -0.57$).
- `danceability–valence`: correlación positiva moderada ($r \approx 0.49$).
- `energy–valence`: correlación positiva moderada ($r \approx 0.26$).
- `instrumentalness–valence`: correlación negativa moderada ($r \approx -0.33$).

IV-C. Discusión del EDA

Estos hallazgos confirman que el espacio acústico no es aleatorio: existen ejes semánticos interpretables (intensidad, positividad y grado acústico) y redundancia parcial entre variables. Por ello, el uso de técnicas de reducción de dimensionalidad y escalado resulta metodológicamente necesario antes del clustering basado en distancia.

V. Proceso de preprocesamiento

V-A. Detección de outliers

Se aplicó inspección por boxplots y filtros de negocio para asegurar la integridad de los datos acústicos:

- **Duración:** se conservaron pistas entre 1 y 8 minutos ($60{,}000 \leq$ `duration_ms` $< 480{,}000$).
- **Loudness:** se descartaron registros con `loudness` >0 dB.
- **Speechiness:** se filtraron valores mayores o iguales a 0.9 para excluir contenido predominantemente hablado.
- **Tempo:** se eliminaron valores no positivos (`tempo` ≤ 0).

V-B. Tratamiento de la asimetría

Para mitigar la fuerte asimetría positiva detectada en el análisis exploratorio, se aplicó la transformación logarítmica $\log(1 + x)$ a las variables `instrumentalness`, `speechiness` y `liveness`. Esta corrección es fundamental para los algoritmos basados en distancia, como K-Means, que requieren distribuciones más simétricas para un desempeño óptimo.

V-C. Codificación Cíclica (Circular Encoding)

Se sustituyó la binarización simple por una codificación cíclica mediante transformaciones de seno y coseno para las variables `key` (tonalidad) y `time_signature` (compás). Este enfoque preserva la proximidad musical real —como la adyacencia entre las notas Do (0) y Si (11) en el círculo cromático— y la naturaleza periódica de los compases, evitando errores de interpretación ordinal.

V-D. Escalado y reducción de dimensionalidad

Se implementó la estandarización mediante *StandardScaler* (media = 0, std = 1) para equilibrar el peso de todas las variables acústicas. Finalmente, el análisis PCA permitió sintetizar el espacio acústico reteniendo el 80 % de la varianza acumulada a través de 9 componentes principales, eliminando la redundancia detectada en el EDA.

V-E. Eliminación de duplicados

La deduplicación principal se realizó por `track_id` (manteniendo la primera ocurrencia), reduciendo el conjunto de 114,000 a 89,741 filas. Esta decisión evitó sesgos por sobrerepresentación de pistas repetidas.

V-F. Eliminación de variables

Se eliminaron las siguientes variables por considerarse no valiosas para el análisis: Unnamed,track id,album name, track name o inconvenientes para los modelos de agrupamiento.

V-G. Tratamiento de valores perdidos

La inspección de nulos mostró ausencia casi total de faltantes (proporción residual en `artists` cercana al 0.001 %). Se aplicó eliminación de registros incompletos en variables críticas para mantener consistencia analítica.

V-H. Integración

Aunque se trabajó con una fuente principal, se integraron dos niveles de información dentro del pipeline: metadatos musicales (artistas, género, álbum al que pertenece) y descriptores acústicos. Además, se incorporó el marco conceptual de activación-valencia de Russell [2] para interpretar estados de ánimo sobre las variables `energy` y `valence`.

V-I. Agregación

Se aplicaron operaciones de *group-by* para sintetizar comportamiento por categorías, especialmente en el análisis `mode` vs. rangos de `valence`. Esto permitió comparar proporciones relativas entre modo mayor y menor a lo largo del espectro afectivo.

V-J. Discretización

La variable `valence` se discretizó en 10 intervalos uniformes de amplitud 0.1. Esta transformación facilitó:

- lectura comparativa por bandas emocionales,
- visualizaciones porcentuales por modo,
- interpretación semántica para segmentación de estados de ánimo.

V-K. Muestreo

Para la versión final de preparación se preservó el máximo de información posible (sin submuestreo agresivo), dado el carácter multigénero del problema. El muestreo estratificado se dejó como mecanismo auxiliar para pruebas rápidas de modelos, manteniendo la prioridad en representatividad global.

V-L. Binarización y codificación

Se estandarizaron variables categóricas discretas:

- `explicit`: codificación en categoria "v.º "f.
- `mode`: codificación de modalidad mayor/menor.
- `key` y `time_signature`: mapeo a formato categórico para evitar interpretaciones ordinales incorrectas.

V-M. Escalado y reducción de dimensionalidad

Se normalizaron variables clave y se trabajó en un dataset mayoritariamente en escala [0,1]. Se utilizó normalización Min-Max en variables (`loudness`, `tempo`, `popularity`), según:

$$x' = \frac{x - x_{\text{mín}}}{x_{\text{máx}} - x_{\text{mín}}}. \tag{1}$$

Como paso de reducción de dimensionalidad, el análisis PCA reportó aproximadamente 40,78 % de varianza explicada en 2 componentes y cerca de 80 % en 7 componentes, resultado coherente con una estructura multivariada compleja.

Cuadro II
TRAZABILIDAD DEL PIPELINE DE LIMPIEZA

Etapa	Filas
Carga inicial	114,000
Deduplicación por `track_id`	89,741
Filtro de duración (1–8 min)	87,252
Filtro `loudness` <= 0	87,185
Filtro `speechiness` <0.9	86,611
Filtro `tempo` >0	86,467

VI. Resultados de Preparación para Clustering

Tras remover variables no numéricas para modelos basados en distancia, se obtuvo una matriz de 86,467 instancias y 11 atributos cuantitativos. Este conjunto quedó listo para la etapa de agrupamiento no supervisado (método del codo, silueta, K-means y clustering jerárquico), con trazabilidad completa de decisiones de preprocesamiento.

Adicionalmente, el contraste entre `valence` y `mode` mostró diferencias acotadas, mientras que la relación `valence`–`energy` sí evidenció potencial descriptivo para perfilar estados de ánimo (e.g., alta energía/alta valencia frente a baja energía/baja valencia).

VII. Minería de reglas de asociación

VII-A. Preparación de datos y discretización

Para el descubrimiento de patrones de co-ocurrencia, se transformó el conjunto de datos a un formato transaccional. Dado que los algoritmos de asociación operan sobre ítems discretos, las variables acústicas continuas se procesaron mediante la técnica de discretización por cuantiles (*quantiles*), dividiendo cada atributo en tres niveles de intensidad: **bajo, medio y alto**. Este enfoque permitió garantizar clases equilibradas en las transacciones, facilitando la identificación de reglas significativas basadas en la distribución real de los datos musicales.

VII-B. Resultados: El Núcleo Acústico-Energético

El análisis reveló la existencia de un patrón denominado el **"Núcleo Acústico-Energético"**, compuesto por las asociaciones más robustas del dataset. La regla con mayor relevancia estadística fue $\{\text{acusticidad_alta, volumen_bajo}\} \implies \{\text{energy_baja}\}$, la cual alcanzó un **lift de 2.72**.

Este valor indica que la co-ocurrencia de estos atributos es 2.72 veces más frecuente de lo esperado por azar. Asimismo,

el modelo reportó una confianza del 91 %, lo que implica que casi la totalidad de las canciones con alta acusticidad y bajo volumen poseen niveles reducidos de energía. Estos hallazgos validan la consistencia física y musical de los descriptores de Spotify, confirmando una estructura bidireccional y robusta en el eje de intensidad.

VII-C. Comparativa de Algoritmos: Apriori vs. FP-Growth

Se evaluaron los algoritmos Apriori y FP-Growth bajo umbrales idénticos de soporte (0.15) y confianza (0.65). Ambos modelos demostraron una alta consistencia al identificar las mismas reglas de mayor *lift*. No obstante, **FP-Growth resultó ser más conservador**, generando un número menor de reglas (9 frente a las 21 de Apriori) debido a su estrategia de construcción de árboles comprimidos (*FP-tree*) que evita la generación exhaustiva de candidatos. A pesar de esta diferencia en la cobertura, la coincidencia en los valores máximos de *lift* respalda la validez de los patrones identificados como reflejos reales del espacio musical.

VIII. Segmentación de Estados de Ánimo (Clustering)

VIII-A. Determinación del número óptimo de clusters

La selección del número de grupos (K) se realizó mediante la evaluación convergente de diversas métricas de validación interna. Si bien el índice de Davies-Bouldin sugirió una partición más fina ($K = 12$), el **coeficiente de silueta** identificó un valor óptimo de **5 clusters** con una puntuación de 0.140. Esta elección se justificó al representar la estructura más equilibrada entre cohesión y separación, permitiendo obtener segmentos con una identidad musical y semántica clara que no se lograba con particiones más granulares.

VIII-B. Perfilamiento semántico de los segmentos

El análisis de los centroides en el espacio de variables originales permitió identificar cinco perfiles musicales bien diferenciados:

- **Cluster 0 (Alegre y bailable):** Canciones con alta positividad emocional y marcado protagonismo rítmico, ideales para contextos sociales distendidos.
- **Cluster 1 (Intenso y electrónico):** Segmento con la energía más alta del dataset y baja acusticidad, característico de sonidos potentes y distorsionados como el rock o la electrónica pesada.
- **Cluster 2 (Energético equilibrado):** Perfil versátil que combina dinamismo y motivación con una positividad emocional neutral.
- **Cluster 3 (Melancólico e introspectivo):** Grupo definido por baja energía, baja valencia y alta acusticidad, invitando a la calma y la quietud.
- **Cluster 4 (Reflexivo y expresivo):** Caracterizado por una acusticidad moderada y el nivel más alto de *speechiness*, sugiriendo una fuerte carga narrativa o lírica.

VIII-C. Validación en el Modelo de Russell

Para validar la coherencia emocional de la segmentación, los centroides de cada cluster se proyectaron en el **Modelo Circunflejo de Russell (1980)**, organizando los grupos en el plano bidimensional de *Valence* (positividad) y *Energy* (intensidad). Los resultados confirmaron que los clusters capturan dimensiones afectivas funcionales de manera estructurada, posicionando claramente regiones de euforia, introspección, energía y neutralidad emocional. Esta validación demuestra que los descriptores acústicos de Spotify son capaces de modelar la experiencia emocional de la música sin depender exclusivamente de etiquetas de género convencionales.

IX. Análisis de Modelos Alternativos y Visualización

IX-A. Clustering Probabilístico con GMM y Ambigüedad Emocional

Para complementar el agrupamiento rígido de K-Means, se implementó el modelo de *Gaussian Mixture Models* (GMM), el cual permite una asignación probabilística de las canciones (*soft clustering*). Este enfoque resulta más adecuado para la naturaleza continua de la música, donde los estados de ánimo no poseen fronteras discretas. Un hallazgo fundamental fue el uso de la **entropía de las probabilidades** para identificar la **.ªmbigüedad emocional"**: las canciones con alta entropía representan perfiles híbridos que combinan características de múltiples estados de ánimo. El modelo reportó que un 0.7 % de la muestra presenta una ambigüedad significativa, lo que constituye información valiosa para sistemas de recomendación que requieren pistas versátiles.

IX-B. Detección de Ruido mediante HDBSCAN

Se aplicó el algoritmo HDBSCAN para descubrir la estructura de los datos basada en la densidad local sin necesidad de predefinir el número de clusters. A diferencia de otros métodos, HDBSCAN permite identificar formalmente el **ruido acústico** (etiqueta -1), correspondiente a canciones que no encajan en ningún perfil denso o definido. El análisis detectó 1,066 canciones (1.2 % del dataset) clasificadas como ruido, las cuales representan pistas con perfiles atípicos o de transición emocional que los modelos tradicionales fuerzan a agrupar erróneamente.

IX-C. Visualización No Lineal con UMAP

La estructura global del espacio acústico se validó mediante la técnica de reducción de dimensionalidad no lineal **UMAP** (*Uniform Manifold Approximation and Projection*). La proyección en dos dimensiones confirmó visualmente la existencia de agrupaciones naturales en forma de **ïslas"de densidad**, lo que demuestra que el espacio musical no es homogéneo sino que posee regiones acústicas bien diferenciadas. Asimismo, al colorear el mapa por la variable *valence*, se observó un gradiente continuo que atraviesa las regiones, validando que las dimensiones emocionales están organizadas espacialmente de manera coherente con los clusters identificados.

X. Clasificación de Género Musical

X-A. Planteamiento del problema supervisado

Como complemento a la segmentación no supervisada por estados de ánimo, se formuló un problema de clasificación multiclase para predecir la etiqueta editorial de género (`track_genre`) a partir de descriptores acústicos preprocesados. A diferencia del *clustering*, donde la variable de género se empleó únicamente como referencia externa de validación, en esta etapa `track_genre` actúa como variable objetivo.

Se utilizó la matriz `df_model` con 14 atributos numéricos: `danceability`, `energy`, `loudness`, `valence`, `tempo`, `acousticness`, `instrumentalness`, `speechiness`, `liveness`, `key_sin`, `key_cos`, `time_sig_sin`, `time_sig_cos` y `mode`. Estas características conservan la información acústica en su espacio original (sin proyección PCA), lo cual resulta apropiado para modelos supervisados que pueden aprovechar relaciones no lineales entre variables. El problema abarca aproximadamente 114 clases de género, con un desbalance inherente derivado de la estructura del dataset.

X-B. Partición estratificada de datos

El conjunto se dividió en entrenamiento (80 %) y prueba (20 %) mediante muestreo estratificado sobre `track_genre`, preservando la proporción relativa de cada clase en ambas particiones. Sobre la matriz final de 86,467 instancias, esto corresponde a ∼69,174 registros de entrenamiento y ∼17,293 de prueba. Se conservaron además los índices originales (`idx_train`, `idx_test`) para alinear las predicciones con el *dataframe* de resultados del proyecto.

X-C. Modelo principal: Random Forest

El clasificador de referencia fue un *Random Forest* con 100 árboles, profundidad máxima de 20, `min_samples_split`=10, `min_samples_leaf`=5 y `class_weight='balanced'` para mitigar el desbalance entre géneros. Posteriormente se aplicó ajuste de hiperparámetros mediante *RandomizedSearchCV* (10 iteraciones, validación cruzada de 3 pliegues, métrica *accuracy*), explorando `n_estimators`, `max_depth`, `min_samples_split` y `min_samples_leaf`. El estimador optimizado (`best_rf`) quedó configurado con `n_estimators=200` y `max_depth=None`, y se adoptó como modelo final para predicción y exportación de resultados.

X-D. Comparativa de algoritmos supervisados

Para contextualizar el desempeño del Random Forest, se compararon tres clasificadores bajo las mismas particiones `X_train`/`X_test` y la misma variable objetivo `y_genre`:

- **Random Forest:** ensamble de árboles, robusto ante relaciones no lineales y desbalance de clases.
- **Histogram Gradient Boosting:** boosting secuencial con pesos balanceados por muestra.
- **Regresión logística multinomial:** línea base lineal e interpretable.

La Tabla III resume las métricas obtenidas en el conjunto de prueba. El Random Forest superó claramente a las alternativas en *accuracy*, F1 macro y F1 ponderado.

Cuadro III
Comparativa de clasificadores para predicción de `track_genre`

Modelo	Accuracy	F1 macro	F1 weighted	Tiempo (s)
Random Forest	**0.303**	**0.286**	**0.287**	32.5
Histogram Gradient Boosting	0.201	0.192	0.198	17.9
Regresión logística	0.143	0.109	0.116	257.8

Con ∼114 clases y etiquetas frecuentemente solapadas acústicamente (por ejemplo, `electronic` frente a `edm`), un 30.3 % de aciertos representa un techo razonable usando únicamente descriptores de audio. La baja precisión de la regresión logística (∼14.3 %) indica que la relación entre características acústicas y género **no es principalmente lineal**, lo que justifica el uso de métodos basados en árboles. Aunque Histogram Gradient Boosting fue más rápido (17.9 s frente a 32.5 s del Random Forest), no superó al ensamble en precisión con la configuración evaluada.

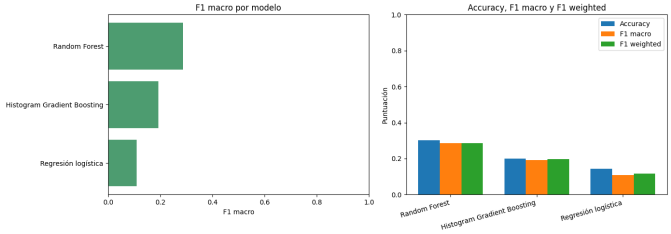


Figura 1. Comparativa de desempeño y coste computacional entre Random Forest, Histogram Gradient Boosting y regresión logística.

X-E. Importancia de variables en el Random Forest

El análisis de importancia de características del Random Forest permitió identificar qué descriptores acústicos aportan mayor poder discriminativo para la predicción de género. En general, variables asociadas a energía, bailabilidad, acusticidad y valencia concentraron mayor peso relativo, coherentes con la estructura del espacio acústico descrita en el EDA y en las reglas de asociación.

X-F. Relación entre clasificación y clustering

La clasificación supervisada de género y la segmentación no supervisada por estado de ánimo responden objetivos distintos pero complementarios. Los clusters agrupan canciones según ejes de valencia y energía en el marco de Russell, mientras que el Random Forest intenta recuperar la etiqueta editorial `track_genre`. Por ello, ambos análisis no compiten sino que se refuerzan: el *clustering* revela estructura emocional funcional y la clasificación cuantifica hasta qué punto los descriptores acústicos permiten reconstruir categorías culturales de género.

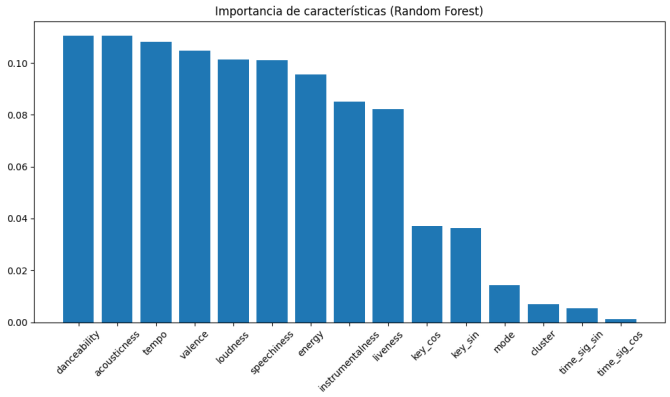


Figura 2. Importancia de características del Random Forest para la clasificación de `track_genre`.

X-G. *Limitaciones de la clasificación*

Persisten limitaciones relevantes: géneros minoritarios con F1 bajo, confusión entre estilos afines y ausencia de letras o metadatos textuales. La exportación de predicciones (`predicted_genre`) se realizó para el conjunto de prueba, dejando el resto de filas sin etiqueta predicha hasta una inferencia completa en producción.

XI. Conclusiones

El desarrollo del proyecto permitió construir una representación acústica consistente y analíticamente robusta del espacio musical de Spotify, integrando técnicas de preprocesamiento, reducción de dimensionalidad y clustering no supervisado para identificar patrones emocionales latentes en las canciones.

XI-A. *Preprocesamiento y preparación de datos*

El dataset original, compuesto por más de 114 000 canciones distribuidas en 125 géneros musicales, fue sometido a un proceso riguroso de limpieza y depuración. La eliminación de duplicados mediante `track_id` redujo redundancias estructurales importantes entre géneros y versiones repetidas de canciones. Asimismo, el tratamiento de valores nulos y el filtrado de outliers en variables como `duration_ms`, `loudness`, `speechiness` y `tempo` permitió obtener un conjunto de datos más representativo y estable para modelado.

Las transformaciones logarítmicas aplicadas sobre `instrumentalness`, `speechiness` y `liveness` corrigieron distribuciones altamente asimétricas, mejorando la capacidad discriminatoria de los algoritmos basados en distancia. Adicionalmente, la implementación de *Circular Encoding* para `key` y `time_signature` preservó adecuadamente la naturaleza periódica de estas variables musicales, evitando distorsiones asociadas a codificaciones lineales tradicionales.

Finalmente, la estandarización mediante `StandardScaler` aseguró condiciones apropiadas para PCA y clustering, reduciendo sensibilidad a escalas distintas y a outliers residuales.

XI-B. *Hallazgos del análisis exploratorio*

El análisis exploratorio evidenció relaciones estructurales coherentes entre las variables acústicas. Se identificaron correlaciones importantes, como la asociación positiva entre `energy` y `loudness`, y la relación inversa entre `acousticness` y `energy`, confirmando redundancia parcial entre ciertas dimensiones acústicas.

Además, las variables `valence` y `energy` mostraron comportamientos compatibles con el modelo circunflejo de Russell, permitiendo interpretar los clusters desde una perspectiva emocional bidimensional. También se observó que las canciones en modo mayor tienden a presentar valores más altos de `valence`, apoyando la hipótesis de asociación entre tonalidad mayor y emociones positivas.

XI-C. *Reducción de dimensionalidad mediante PCA*

El uso de PCA permitió reducir la dimensionalidad preservando aproximadamente el 80 % de la varianza acumulada del dataset. Esta reducción eliminó redundancia entre variables correlacionadas y facilitó la construcción de modelos de clustering más estables y eficientes computacionalmente.

Los componentes principales obtenidos revelaron dimensiones acústicas interpretables relacionadas con intensidad sonora, complejidad rítmica y carácter instrumental, demostrando que el espacio musical puede representarse mediante un conjunto reducido de factores latentes sin perder capacidad descriptiva relevante.

XI-D. *Resultados del clustering*

La selección del número de clusters para K-Means se realizó mediante la convergencia de múltiples métricas de validación interna, evitando decisiones arbitrarias. Los clusters obtenidos representan estados emocionales diferenciados que abarcan desde música eufórica y bailable hasta perfiles introspectivos, contemplativos o de alta intensidad emocional.

La validación cruzada utilizando `track_genre`, variable excluida del entrenamiento, confirmó que las agrupaciones descubiertas poseen coherencia musical real, aunque trascienden las categorías tradicionales de género para capturar patrones acústico-emocionales más profundos.

La visualización mediante UMAP reforzó esta interpretación al evidenciar regiones parcialmente diferenciadas dentro del espacio acústico reducido.

XI-E. *Comparación entre algoritmos*

El modelo Gaussian Mixture Models (GMM) complementó el análisis de K-Means al introducir asignaciones probabilísticas, capturando mejor la naturaleza difusa y continua de los estados emocionales musicales. El análisis de entropía permitió identificar canciones híbridas con pertenencia ambigua entre clusters, aspecto especialmente valioso para aplicaciones de recomendación musical.

Por otra parte, HDBSCAN mostró que el espacio acústico de Spotify no presenta regiones densas claramente separadas por vacíos estructurales. Aunque obtuvo métricas internas superiores en ciertos escenarios, concentró la mayoría de

canciones en un único cluster dominante, reduciendo significativamente la interpretabilidad práctica de la segmentación.

Uno de los hallazgos más relevantes de HDBSCAN fue la identificación explícita de canciones consideradas ruido: perfiles acústicos ambiguos que otros algoritmos fuerzan artificialmente a pertenecer a algún grupo. Este resultado sugiere que el espacio musical se comporta más como una distribución continua que como conjuntos densos completamente separados.

XI-F. Resultados de la clasificación supervisada

Se implementó un módulo de clasificación multiclase para predecir `track_genre` a partir de 14 descriptores acústicos preprocesados. El Random Forest, con ajuste de hiperparámetros mediante *RandomizedSearchCV*, obtuvo el mejor desempeño frente a Histogram Gradient Boosting y regresión logística multinomial, alcanzando un 30.3 % de *accuracy* y un F1 macro de 0.286 sobre $\sim$114 clases en el conjunto de prueba estratificado.

Este resultado confirma que los descriptores acústicos capturan señales parcialmente predictivas de género, aunque con un techo moderado debido al solapamiento entre estilos afines y al carácter cultural de las etiquetas de género. La inferioridad de la regresión logística evidencia relaciones predominantemente no lineales entre atributos acústicos y categorías musicales. Desde el punto de vista operativo, el Random Forest ofreció además un balance favorable entre precisión y coste computacional frente a la regresión logística multinomial.

La clasificación supervisada complementa la segmentación por *clustering*: mientras los clusters organizan canciones por estados emocionales funcionales (valencia–energía), el clasificador intenta recuperar etiquetas editoriales de género. Ambas perspectivas convergen en que la organización musical trasciende categorías rígidas y requiere enfoques híbridos.

XI-G. Limitaciones encontradas

Aunque las características acústicas de Spotify capturan dimensiones fundamentales del estado de ánimo musical, no representan completamente la experiencia emocional de una canción. Elementos semánticos como las letras pueden actuar como contrapunto emocional y modificar significativamente la percepción humana.

Finalmente, el subconjunto de canciones clasificadas como ruido por HDBSCAN constituye una línea de investigación particularmente interesante, ya que podría contener canciones híbridas, transiciones emocionales complejas o perfiles acústicos atípicos no capturados completamente por las variables disponibles.

REFERENCIAS

[1] M. Pandya, "Spotify Tracks Dataset," Kaggle, 2022. [En línea]. Disponible en: https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset. [Consultado: 21 de marzo de 2026].

[2] J. A. Russell, "A Circumplex Model of Affect," *Journal of Personality and Social Psychology*, vol. 39, no. 6, pp. 1161–1178, 1980.

Cuadro IV
REGLAS DE ASOCIACIÓN OBTENIDAS

index	antecedente	consecuente	soporte	confianza	lift
0	{’acusticidad_alta’, ’volumen_bajo’}	{’energy_baja’}	0.1897	0.9087	2.7192
1	{’acusticidad_alta’, ’energy_baja’}	{’volumen_bajo’}	0.1897	0.7897	2.3685
2	{’energy_baja’, ’volumen_bajo’}	{’acusticidad_alta’}	0.1897	0.7692	2.3083
3	{’volumen_bajo’, ’modo_mayor’}	{’energy_baja’}	0.1687	0.7650	2.2891
4	{’energy_baja’, ’modo_mayor’}	{’acusticidad_alta’}	0.1700	0.7389	2.2173

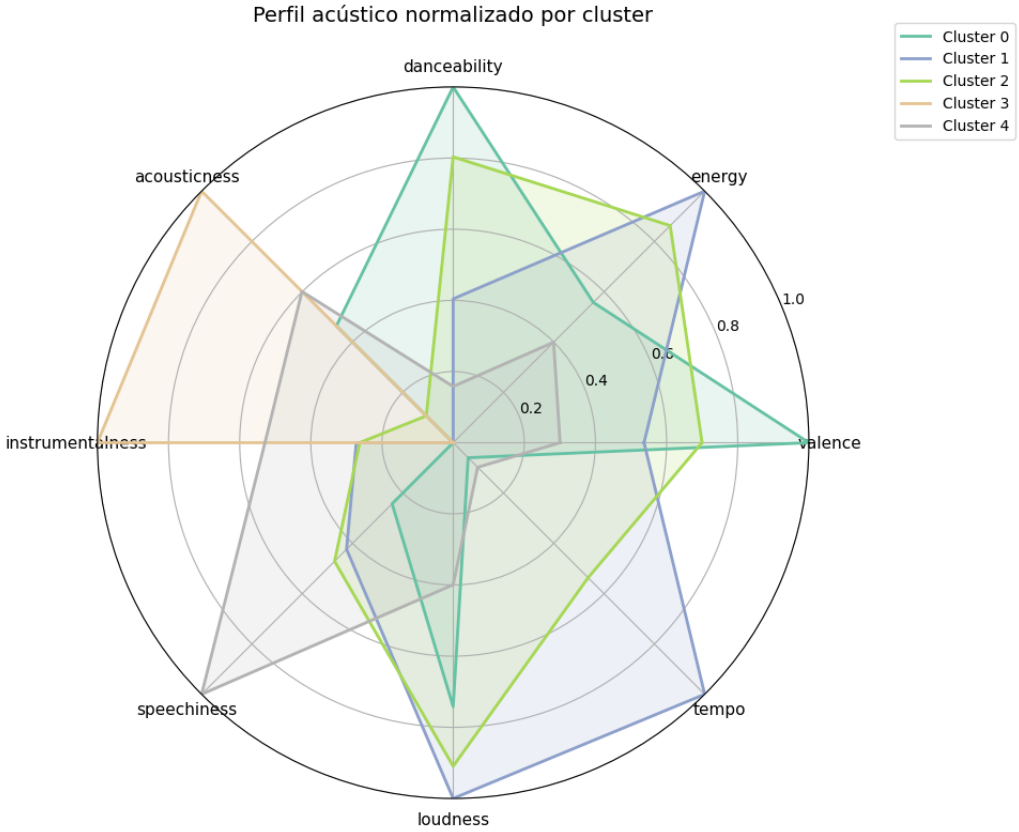


Figura 3. Gráfico de Radar: Perfil promedio de los 5 clusters.

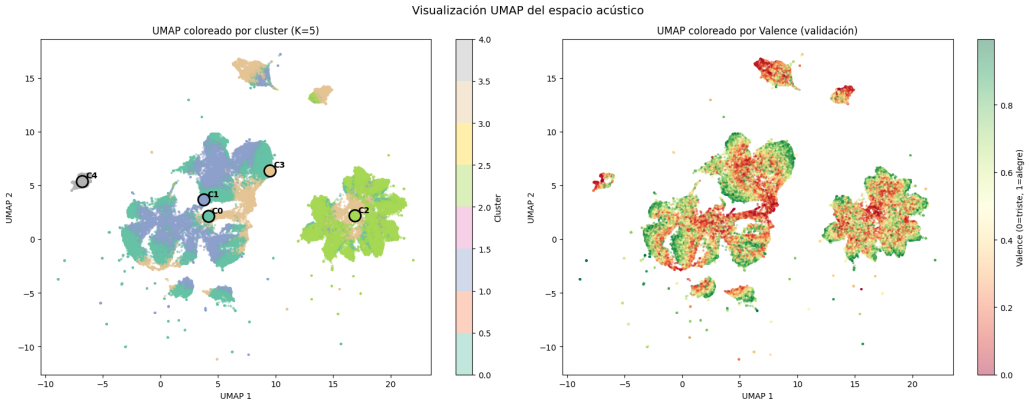


Figura 4. Mapa UMAP: Visualización 2D de la segmentación final.

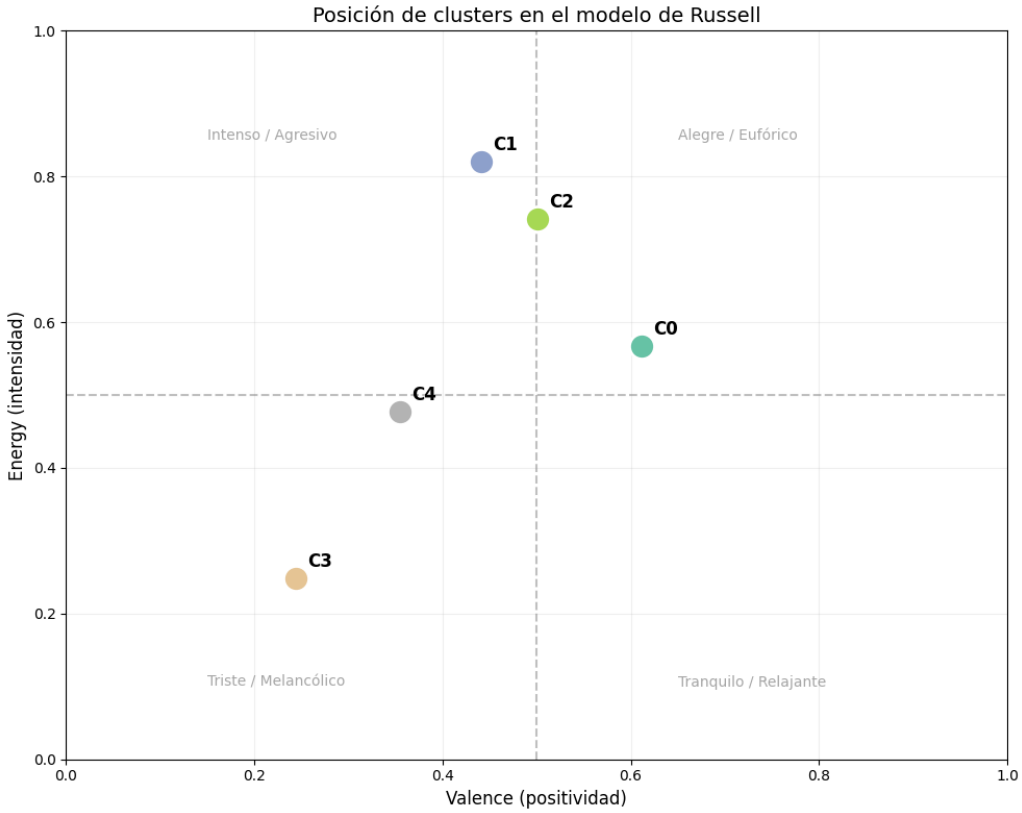


Figura 5. Gráfico de Russell: Posición de los centroides en el plano emocional.